EGM0017 (60h)

# Fluxo e metodologias de projeto de Sistemas Embarcados

Prof. **Josenalde Barbosa de Oliveira** – **UFRN**

 josenalde.oliveira@ufrn.br

Programa de Pós-Graduação em Engenharia Mecatrônica

# Questões de não determinismo e sincronismo

- Onde unidades de processamento (UP) podem executar assincronamente, é provável ocorrer não determinismo.
- Uma computação é não determinística se pode gerar saídas diferentes para uma mesma entrada. Se múltiplas threads executam de forma independente, a velocidade com que concluem tarefas varia de execução para execução e dependem de interações como sistema operacional
- Exemplo: thread id=0, com my_x (privada) previsto = 7

  thread id=1, com my_x (privada) previsto = 19
- Supondo que cada thread execute o código `cout << id << "my_x: " << my_x;`
  - *A saída poderá ser:* `0 my_val: 7; 1 my_x: 19 OU 1 my_x: 19; 0 my_val: 7`
- Outro exemplo: cada thread calcula um inteiro com base no id da thread (my_id) e armazena em `my_val`. É objetivo também adicionar este valor a uma variável compartilhada x. Portanto, cada thread executa algo assim:

```
my_val = computeVal(my_id);
x += my_val;
```

- Sabemos que uma adição exige carregar operandos da memória, colocar em registradores, e depois armazenar o resultado

# Questões de não determinismo e sincronismo

- Eventos possíveis:

| Time | Core 0 | Core 1 |
|---|---|---|
| 0 | Finish assignment to `my_val` | In call to `Compute_val` |
| 1 | Load `x = 0` into register | Finish assignment to `my_val` |
| 2 | Load `my_val = 7` into register | Load `x = 0` into register |
| 3 | Add `my_val = 7` to `x` | Load `my_val = 19` into register |
| 4 | Store `x = 7` | Add `my_val` to `x` |
| 5 | Start other work | Store `x = 19` |

- Quando threads ou processos tentam simultaneamente acessar um recurso, e estes acessos podem resultar em resultados errados, diz-se que que as threads ou processos estão em RACE CONDITION (condição de corrida). A saída depende de quem "ganhar a corrida". No caso em questão a atualização da variável X. Só seria correto se uma das threads garantidamente terminasse antes da outra. Ou seja, a execução precisa ter **ATOMICIDADE**.
- Um bloco de comando que só pode ser executado por uma thread por vez é uma **SEÇÃO CRÍTICA** (mutualmente exclusivo) garantido pelo(a) desenvolvedor(a) no paralelismo explícito.

# Condição de corrida

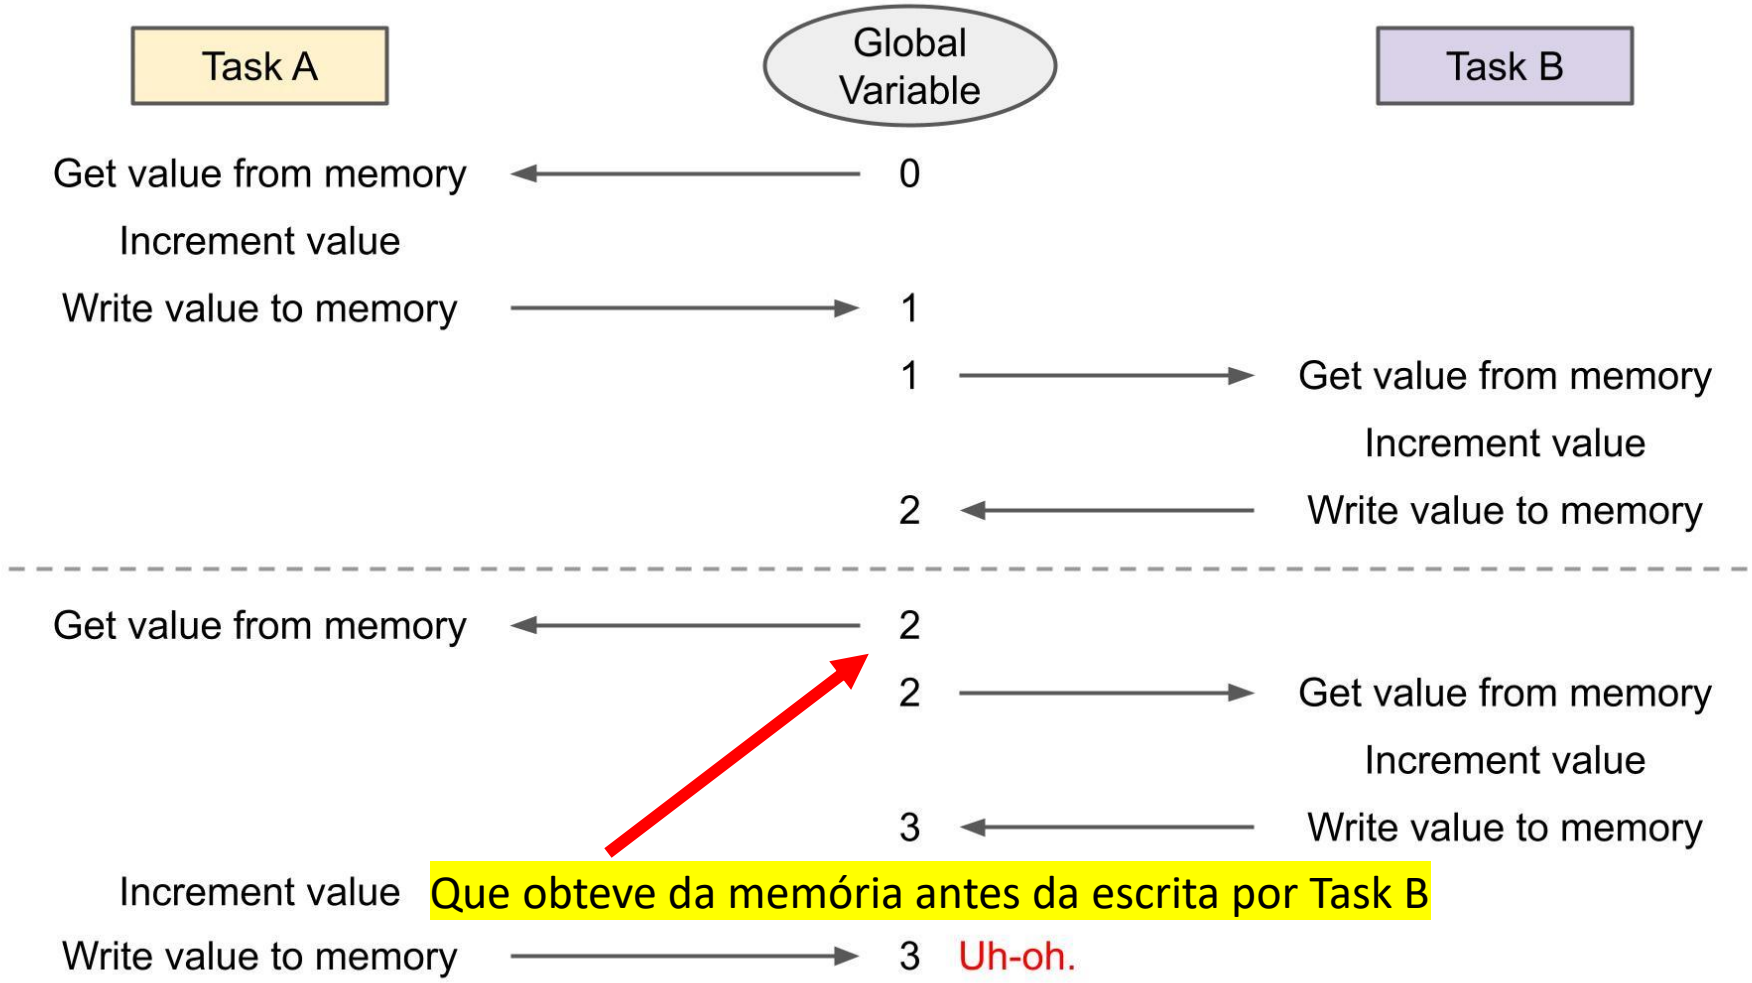

# Questões de não determinismo e sincronismo

- **Exclusão mútua**: trecho de código executa com exclusão mútua se no máximo UMA THREAD pode executar o referido trecho a qualquer momento
- **Atomicidade**: termo utilizado e derivado da comunidade de bancos de dados, onde um conjunto de operações é atômico se OU TODOS EXECUTAM ATÉ O FIM (sem interrupções) ou NENHUM EXECUTA. Ou seja, não é possível verificar execuções parciais.
- No caso da contagem de objetos vista anteriormente:

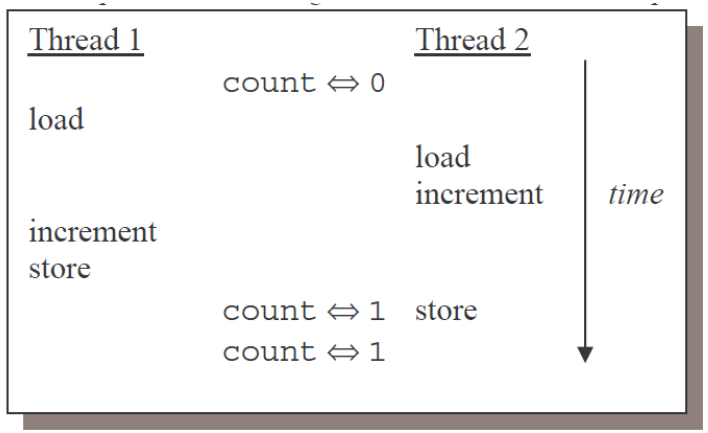


O mecanismo mais comum é um **mutual exclusion lock** (mutex ou lock). Ideia é proteger a seção crítica. Antes da thread executar código na seção, precisa "obter" o mutex chamando função apropriada de **lock** e, ao fim, liberar, com **unlock**. – Recurso do OS

```
my_val = computeVal(my_id);
Lock(&add_my_val_lock);
        x += my_val;
Unlock(&add_my_val_lock);
```

# Questões de não determinismo e sincronismo

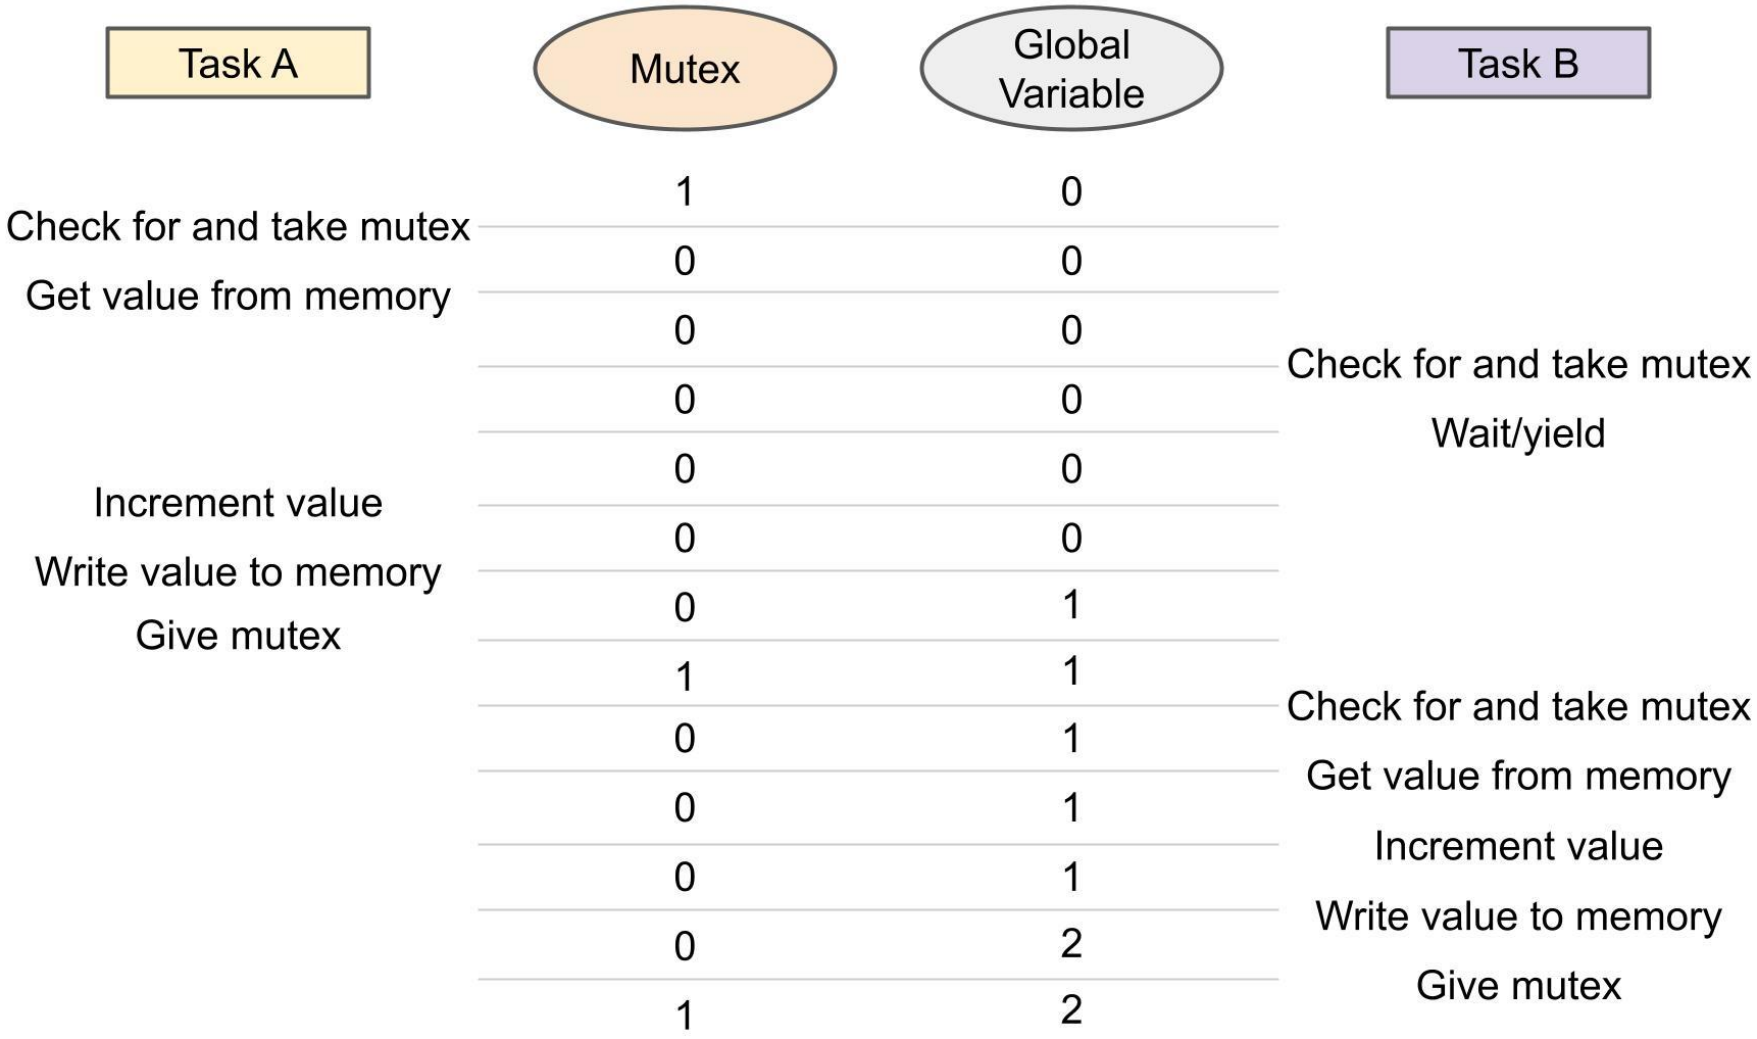

# Questões de não determinismo e sincronismo

- Notamos no trecho de código anterior que não há ordem de acesso à seção crítica, apenas que uma thread por vez atualiza a variável x
- O mutex força serialização da seção crítica, portanto deve ser usado onde realmente for necessário e com execução o mais rápido possível, assim como as ISRs em interrupções

```
1  mutex m;
2
3  void count3s_thread (int id)
4  {
5    /* Compute portion of the array that this thread should work on */
6     int length_per_thread = length/t;
7     int start = id * length_per_thread;
8
9     for (i=start; i<start+length_per_thread; i+)
10    {
11        if (array[i] == 3)
12        {
13           mutex_lock(m);
14           count++;
15           mutex_unlock(m);
16        }
17    }
18 }
```

Esta solução garante atomicidade,
mas eleva o tempo de processamento, devido ao tempo lock/unlock

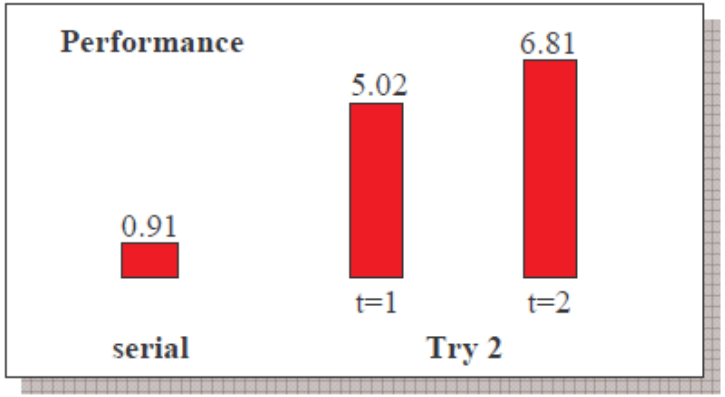


https://github.com/josenalde/flux-embedded-design/blob/main/src/pthread_count3s_mutex_1.cpp

# Questões de não determinismo e sincronismo

- Comparando os códigos 1 e 2, no WSL sobre o SO Windows 11, com Processador Intel® Core™ i7-10510U quad-core com 2 threads por core (8 threads), 16GBRam, com o g++ (13.1.0), usando a função clock() de <ctime> em C++: 0.001 / 0.02 (media 10 execuções)
- Vamos então aumentar a granularidade (menos comunicação, mais computação). Ao invés de acessar a seção crítica sempre que COUNT for incrementada, podemos acumular a contribuição local numa variável PRIVADA à thread, private_count, acessar a seção crítica para atualizar a COUNT compartilhada apenas uma vez por thread. No código 3, 0.002s

```
1 private_count[MaxThreads];
2 mutex m;
3
4 void count3s_thread (int id)
5 {
6   /* Compute portion of the array that this thread should work on */
7    int length_per_thread = length/t;
8    int start = id * length_per_thread;
9
10    for (i=start; i<start+length_per_thread; i++)
11    {
12       if (array[i] == 3)
13       {
14          private_count[t]++;
15       }
16    }
17    mutex_lock(m);
18    count += private_count[t];
19    mutex_unlock(m);
20 }
```

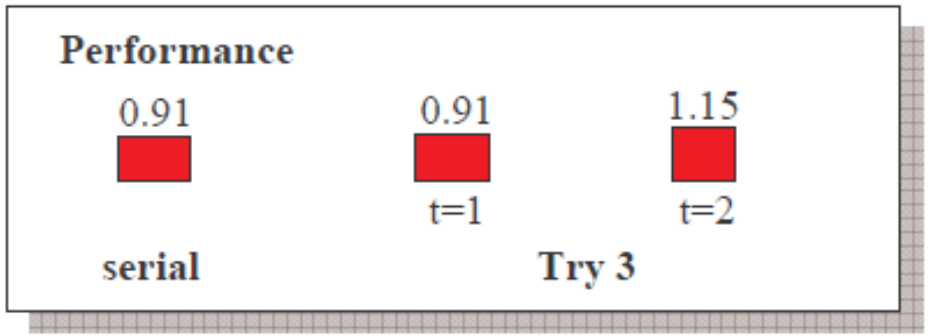


https://github.com/josenalde/flux-embedded-design/blob/main/src/pthread_count3s_mutex_3.cpp

# Outro exemplo com somatório (tarefa) usando a abordagem do código _3

- Cálculo de aproximação para o número PI com N termos

```
1  void* Thread_sum(void* rank) {
2     long my_rank = (long) rank;
3     double factor;
4     long long i;
5     long long my_n = n/thread_count;
6     long long my_first_i = my_n*my_rank;
7     long long my_last_i = my_first_i + my_n;
8     double my_sum = 0.0;
9
10    if (my_first_i % 2 == 0)
11       factor = 1.0;
12    else
13       factor = -1.0;
14
15    for (i = my_first_i; i < my_last_i; i++, factor = -factor) {
16       my_sum += factor/(2*i+1);
17    }
18    pthread_mutex_lock(&mutex);
19    sum += my_sum;
20    pthread_mutex_unlock(&mutex);
21
22    return NULL;
23 }  /* Thread_sum */
```

# Outro exemplo com cálculo matricial (tarefa) usando a abordagem do código _3

- Dada a dimensão da matrix m x n, a matriz A e o vetor x, calcular y
- Ideia: dividir as linhas da matriz e as threads calculam suas saídas independente

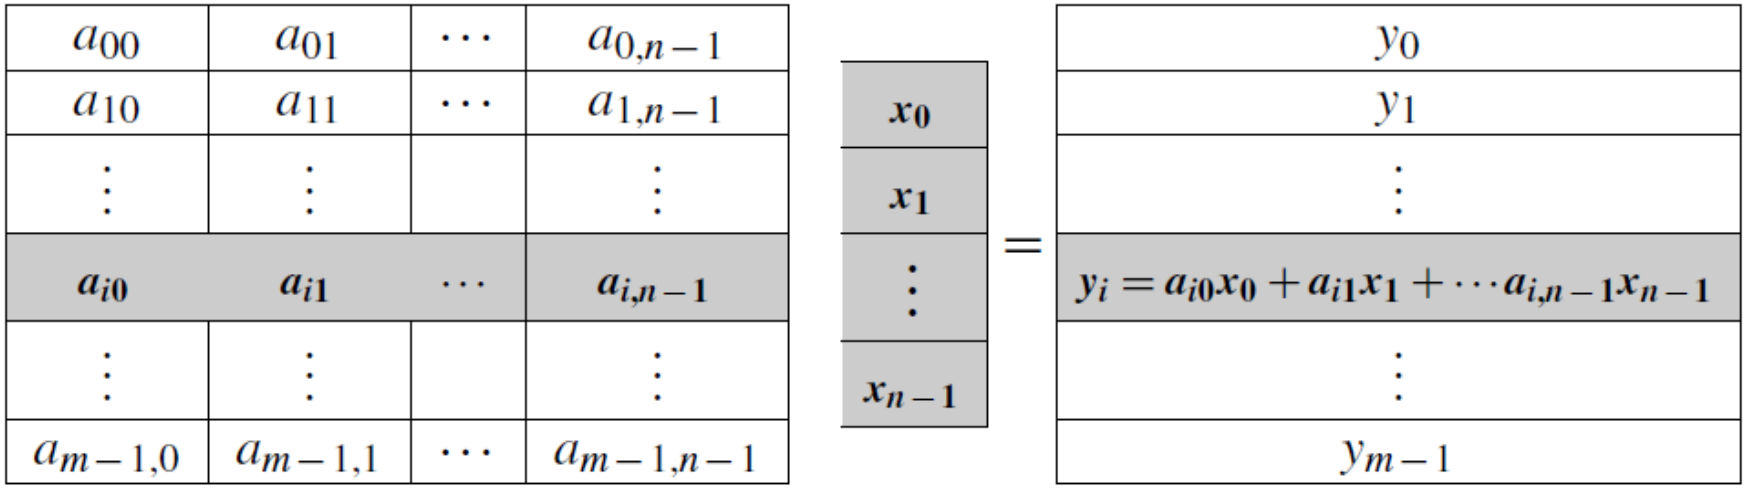


$$y_{n\times 1} = A_{m\times n}\mathbf{x}_{\mathbf{n}\times \mathbf{1}}$$